

# Roadmap — ClimaFresh

## Princípio orientador

O fluxograma que você desenhou tem 7 blocos (Raw-Data → Data-Preparation → Climate-Feature Engineering → Feature Store → Problem → Feature Selection → ML), mas nem todos precisam estar prontos para você começar a gerar evidência científica. A prioridade que você definiu — o **feature generator** — está correta: é a peça que carrega a contribuição original da dissertação (as 5 camadas que o tsfresh não tem). Tudo o que vem antes dele (Raw-Data, Data-Preparation) só precisa existir na medida mínima necessária para alimentá-lo; tudo o que vem depois (Feature Store, Feature Selection, ML) só faz sentido depois que houver features para armazenar, podar e consumir.

Por isso o roadmap abaixo segue uma lógica de "**fatia vertical fina primeiro**": construir o caminho completo (dado → feature → resultado) para **um único problema piloto**, com a arquitetura em camadas já modular, e só depois expandir em largura (mais camadas, mais problemas, mais comparações).

**Suposição que estou assumindo** (me corrija se quiser mudar): o problema piloto será **produtividade de soja** (regressão), por ser o mais simples dos três estudos de caso — dado tabular direto, sem o desbalanceamento de classes de enchentes/ferrugem e sem depender de rótulos fitopatológicos mais difíceis de obter. Se preferir começar por outro, é só trocar a ordem da Fase 2.

---

**Visão geral das fases**

Fase 0 — Fundação mínima  
de dados



Fase 1 — Feature Generator,  
camadas 1-5



Fase 2 — Prova de conceito:  
ClimaFresh vs tsfresh vs cru



Fase 3 — Feature Store



Fase 4 — Feature Selection  
estilo FRESH



Fase 5 — Expansão:  
enchentes e ferrugem



Fase 6 — Benchmark  
completo: 4 abordagens  
incl. GRU



Fase 7 — Métricas formais  
de avaliação



Fase 8 — Generalização  
geográfica

---

## Fase 0 — Fundação mínima de dados

**Objetivo:** ter o menor pipeline possível de Raw-Data + Data-Preparation que já produza uma série tabular limpa e padronizada, suficiente para alimentar o gerador de features.

- Escolher **uma** fonte de dados para começar (sugestão: INMET, por ter estações no Paraná e granularidade diária/horária já tratável; ERA5 fica bem para quando precisar de cobertura espacial contínua).
- Definir o esquema tabular padrão de entrada do framework: `(lat, long, timestamp, variável, valor)` — é o contrato que faz o resto do pipeline ser "agnóstico" à origem do dado, como você já registrou na sinopse.
- Tratamento mínimo: dados faltantes (pode ser um flag simples por enquanto, interpolação fica para depois), padronização de unidades.
- **Critério de saída da fase:** um dataset de teste (pode ser recorte pequeno, algumas estações/anos) já no formato padrão, pronto para o gerador de features.

## Fase 1 — Feature Generator (prioridade máxima)

**Objetivo:** implementar a arquitetura em camadas de forma modular, para que cada camada seja testável isoladamente e já gere valor incremental.

Ordem sugerida das camadas (da mais simples/barata para a mais específica):

1. **Camada 1 — Estatísticas gerais** (média, max, min, skew, kurtosis): é essencialmente reimplementar o padrão tsfresh. Vale começar aqui porque valida a arquitetura do pipeline (entrada → extração → saída tabular) sem ainda depender de lógica climática específica.
2. **Camada 2 — Índices ETCCDI/WMO** (dias secos consecutivos, chuva intensa, SPI): primeira camada que já é diferencial real do ClimaFresh frente ao tsfresh.
3. **Camada 4 — Features físicas derivadas** (VPD, ponto de orvalho, sensação térmica): sugiro adiantar essa antes da camada 3, porque são fórmulas fechadas (sem necessidade de decomposição estatística), rápidas de implementar e de validar (dá para comparar contra fórmulas de referência conhecidas).
4. **Camada 3 — Climatologia, tendência, sazonalidade, wavelets:** é a mais custosa de implementar corretamente (STL + wavelets), por isso mais para o fim dentro desta fase.
5. **Camada 5 — Features espaciais/vizinhança e altitude:** deixar por último porque depende de ter mais de um ponto/estação no dataset de teste, e de decisões de design (raio de vizinhança, forma de agregação) que ficam mais claras depois que as camadas univariadas já estiverem estáveis.

**Critério de saída da fase:** para o dataset da Fase 0, o gerador produz um vetor de features por ponto/janela, cobrindo pelo menos as camadas 1, 2 e 4.

## Fase 2 — Prova de conceito

**Objetivo:** gerar a primeira evidência de que o framework tem valor — este é o "provar que é um trabalho válido" que você mencionou.

- Rodar 3 abordagens no problema piloto (soja, regressão): **features cruas**, **tsfresh**, **ClimaFresh** (ainda sem camada 3 e 5, se não estiverem prontas).
- Métrica simples: RMSE/MAE com o mesmo modelo (ex: regressão linear ou random forest, para não misturar variável de confusão de escolha de modelo) e mesmo split.
- Não precisa ainda de Feature Store nem Feature Selection — pode consumir as features direto em memória/CSV.
- **Critério de saída:** um resultado, mesmo que preliminar, mostrando ClimaFresh  $\geq$  tsfresh em pelo menos uma métrica relevante. Esse resultado sozinho já sustenta a viabilidade da dissertação para banca/qualificação.

## Fase 3 — Feature Store

**Objetivo:** parar de recalcular features toda vez e permitir reuso entre problemas (o conceito central "computar uma vez, reutilizar em N problemas").

- Armazenamento simples primeiro (Parquet ou DuckDB indexado por lat/long/time) — não precisa de infraestrutura pesada nesta fase.
- Otimizar indexação/consulta automática fica como iteração futura, como você mesmo já anotou no board.

## Fase 4 — Feature Selection (estilo FRESH)

**Objetivo:** implementar a poda, já que a Fase 2 provavelmente vai gerar muitas features redundantes.

- Teste estatístico individual + correção de p-values (Benjamini-Yekutieli)
- Remoção de features irrelevantes
- Teste de correlação entre features + poda por correlação
- Feature importance via random forest + poda por importância

Fica depois da Feature Store porque faz mais sentido podar em cima de um repositório já populado e reutilizável do que refazer a poda a cada experimento.

## Fase 5 — Expansão para os demais problemas

**Objetivo:** validar o conceito de reuso espacial entre problemas.

- Aplicar o pipeline completo (agora já com Feature Store + Feature Selection) em **ocorrência de enchentes** (classificação) e **ferrugem asiática** (classificação/regressão).
- Esse é o momento de testar concretamente se as mesmas features regionais (calculadas uma vez) aceleram/melhoram os três problemas, que é a tese central da

sua proposta.

## Fase 6 — Benchmark comparativo completo

**Objetivo:** protocolo experimental completo com as 4 abordagens da sua sinopse.

- Features cruas, tsfresh, ClimaFresh, **GRU** (esse último é o mais custoso de implementar bem — deixar por último faz sentido porque é uma abordagem totalmente diferente, de representação aprendida, e não depende de nada das fases anteriores).
- Mesmos splits (LOYO / LORO) para todas as abordagens, nos 3 estudos de caso.

## Fase 7 — Métricas formais de avaliação

**Objetivo:** consolidar os dois eixos de avaliação da sinopse.

- Tempo de processamento (ClimaFresh vs tsfresh, em diferentes volumes e resoluções).
- Ganho de desempenho preditivo (RMSE/MAE para soja; F1/AUC para enchentes e ferrugem) nas 4 abordagens.

## Fase 8 — Generalização geográfica

**Objetivo:** tratar como extensão/trabalho futuro, não bloqueante para a dissertação.

- Testar o framework fora do Paraná só depois que o núcleo estiver validado — é a fase de menor prioridade porque não muda a contribuição central, só a abrangência.

---

## Resumo de dependências críticas

| Fase | Depende de               | Pode começar em paralelo com                         |
|------|--------------------------|------------------------------------------------------|
| 0    | —                        | —                                                    |
| 1    | Fase 0                   | —                                                    |
| 2    | Fase 1 (camadas 1, 2, 4) | Fase 1 (camadas 3, 5) pode continuar em paralelo     |
| 3    | Fase 1 completa          | Fase 2                                               |
| 4    | Fase 3                   | —                                                    |
| 5    | Fase 3 e 4               | —                                                    |
| 6    | Fase 5                   | Implementação da GRU pode começar antes, em paralelo |

| Fase | Depende de | Pode começar em paralelo com |
|------|------------|------------------------------|
| 7    | Fase 6     | —                            |
| 8    | Fase 6/7   | —                            |
|      |            |                              |
|      |            |                              |

### Perguntas em aberto para refinar o roadmap

- O problema piloto da Fase 2 deve mesmo ser soja, ou você já tem dados de enchentes/ferrugem mais prontos?
- Qual o prazo do mestrado / há uma data de qualificação que deva pautar até onde ir antes de precisar de resultado (isso pode mudar quanto detalhar a Fase 1 antes de pular para a Fase 2)?
- A GRU (Fase 6) é algo que você pretende implementar do zero ou usar como baseline já existente na literatura/framework pronto?